

Міністерство освіти і науки України
Національний технічний університет України “Київський політехнічний інститут
імені Ігоря Сікорського”
Кафедра обчислювальної техніки ФІОТ

ЗВІТ
з лабораторної роботи №1
з навчальної дисципліни «Технології Data Science для завдань електронної комерції»
Тема:
“ПІДГОТОВКА ТА АНАЛІЗ ДАНИХ ДЛЯ СТАТИСТИЧНОГО НАВЧАННЯ”

Виконав:

Студент 1 курсу кафедри ІІІ ФІОТ

Навчальної групи ІІІ-51мн

Сергій ПАНЧЕНКО

Перевірив:

Професор кафедри ОТ ФІОТ

Олексій ПИСАРЧУК

1 Мета

Виявити дослідити та узагальнити особливості застосування методів статистичного навчання для задач визначення статистичних характеристик вхідного потоку даних з

2 Завдання

Лабораторія провідної IT-компанії реалізує масштабний проект розробки універсальної платформи з обробки Big Data масиву статистичних даних поточного спостереження для виявлення закономірностей і прогнозування розвитку контрольованого процесу. Платформа передбачає розташування back-end компоненти на власному хмарному сервері з наданням повноважень користувачам заздалегідь адаптованого front-end функціоналу універсальної платформи.

Замовниками ресурсів платформи є: державні та комерційні компанії валютного трейдингу для прогнозування динаміки зміни курсу валют та ціни інших товарів; метеорологічні служби для прогнозування параметрів метеоумов; департаменти охорони здоров'я для прогнозування зміни показників епідеміологічних ситуацій тощо.

Вам, як Data Science Engineer поставлено завдання.

Завдання III рівня – максимально 9 балів.

1. Провести парсинг самостійно обраного сайту. Вміст даних, що підлягають парсингу – обрати самостійно.
2. Результати парсингу зберегти у файлі. Тип файлу обрати самостійно.
3. Оцінити динаміку тренду реальних даних.
4. Здійснити визначення статистичних характеристик результатів парсингу.
5. Синтезувати та верифікувати модель даних, аналогічних за трендом і статистичними характеристиками реальним даним, які є результатом парсингу.
6. Провести аналіз отриманих результатів.

3 Результати виконання лабораторної роботи.

3.1 Синтезована математична модель перетворень графічних об'єктів відповідно до індивідуального завдання.

3.2 Блок схема алгоритму та її опис.

3.3 Опис структури проекту програми.

3.4 Результати роботи програми відповідно до завдання.

3.5 Програмний код.

Програмний код послідовно реалізує алгоритм рис.1 та спрямовано на отримання результатів, поданих вище.

При цьому використано можливості Python бібліотек: pip; pandas; numpy; xlrd; matplotlib.

Контексні коментарі пояснюють сутність окремих скриптів наведеного коду програми.

3.6 Аналіз результатів відлагодження та верифікації результатів роботи програми.

4 Висновки

У ході лабораторної роботи досліджено ефективність багатопотокової обробки.

CPU-bound: Демонструють майже лінійне прискорення до досягнення ліміту фізичних ядер. Основний фактор успіху — рівномірне балансування навантаження між потоками.

Memory-bound: Швидкодія жорстко обмежується пропускнуою здатністю оперативної пам'яті. Реального прискорення вдалося досягти лише завдяки оптимізації доступу до кешу (блокове транспонування).

IO-bound: Багатопоточність дає приріст лише на малих кількостях потоків. Далі продуктивність швидко досягає плато через обмеження дискової підсистеми (IOPS), і додавання нових потоків втрачає сенс.